

Estudo do Modelo

Como o Algoritmo Funciona?

Árvore de Decisão:

A Árvore de Decisão é um algoritmo que aprende fazendo perguntas de forma sequencial, onde a partir dos dados de treino ele descobre quais perguntas fazer e a ordem delas.

Para decidir qual variável usar em cada nó, o algoritmo calcula uma métrica chamada Gini, que mede o grau de mistura entre as classes em cada divisão. Quanto mais separadas ficam as classes após a pergunta, menor o Gini e melhor a variável. É por isso que o odor se torna o nó raiz: ele é a variável que mais reduz a impureza de imediato, separando a maioria dos cogumelos com quase zero ambiguidade, exatamente o que a análise bivariada da EDA já havia revelado.

A estrutura do algoritmo tem três peças:

- **O Nós Raiz:** Que é a primeira pergunta. **No meu Dataset seria a variável odor**, que é a variável mais importante, nela já dá pra saber quais são venenosos ou comestíveis.
- **Nós internos:** São as seguintes perguntas, para caso não forem resolvidas na pergunta anterior. **No meu Dataset, seria as análises que foram na parte de Análise Multivariada**, onde eu trouxe a análise de três e quatro variáveis.
- **Folha:** A decisão final, onde não tem mais nós após ela. Apesar do meu Dataset ter analisado até quatro variáveis, não foi possível chegar até uma folha final totalmente pura, pois ainda havia valores misturados.

Tipo de Problema

O algoritmo resolve classificação ou regressão?

O algoritmo resolve problemas de classificação, visto que o dataset escolhido é em sua totalidade de dados categóricos, a saída dele é de classificação binária, sendo comestível ou venenoso.

Qual seria a variável alvo no dataset escolhido?

A variável alvo é a tipo, que originalmente, antes da tradução e limpeza era type. Ela trás dois valores: Comestível e venenoso.

Parâmetros Básicos do Modelo

max_depth: Esse parâmetro controla a profundidade da árvore. Ela controla quantas perguntas o modelo faz antes de dar a resposta, se não for dado um limite a árvore cresce até o modelo memorizar os dados. No meu dataset, por exemplo, de forma manual cheguei até o nível quatro da árvore.

min_samples_split: Esse parâmetro controla o número mínimo de amostras que um nó precisa ter para poder ser dividido. Evita criar ramificações para grupos muito pequenos e sem muita relevância.

criterion: Esse critério define a métrica que será usada para medir a qualidade de cada divisão, ela vai decidir qual variável usar em cada nó. Podendo ser o método Gini que mede a impureza ou Entropia que mede a incerteza.

Vantagens e Limitações

Vantagens:

- Ele é interpretável, é possível visualizar e entender cada decisão.
- Funciona nativamente com dados categóricos.
- Lida muito bem com dataset balanceados como o que foi analisado.

Limitações:

- Se não tiver controle de profundidade, toda a árvore é memorizada (overfitting) e perde desempenho em dados novos.
 - Um pouco instável, pequenas mudanças de dados podem gerar uma nova árvore completamente diferente.
-

Conexão com o Dataset

Quais variáveis seriam usadas como preditoras?

As variáveis preditoras foram: odor, cor_chapeu, cor_branquias, cor_esporos e regiao. Já o alvo foi o tipo.

Quais predições seriam possíveis fazer?

Pela altíssima qualidade do Dataset, como foi possível verificar no EDA, com separações próximas a 100% em várias combinações. Dado informações de um novo cogumelo, o modelo seria capaz de prever com confiança se é comestível ou venenoso. Tornando o modelo uma ferramenta prática de apoio à decisão em situações reais de coleta na natureza.