

Projeto de IA: MycoGuard — Sistema Inteligente para Classificação e Segurança Micológica

1. Título e Integrantes

- **Nome do projeto:** MycoGuard
- **Integrantes:** Bruno Gomes Silva

2. Problema

- **Qual problema será resolvido?** A dificuldade na identificação rápida e segura de cogumelos selvagens na natureza. A distinção entre espécies comestíveis e altamente letais por leigos ou entusiastas costuma ser ambígua, exigindo cruzamentos complexos de múltiplos atributos visuais e olfativos que desafiam o raciocínio humano a olho nu.
- **Quem é afetado?** Entusiastas de forrageamento (coleta de alimentos selvagens), biólogos em campo, caminhantes/praticantes de ecoturismo e profissionais da área de saúde/toxicologia que precisam de triagem rápida.
- **Por que esse problema é importante?** A ingestão acidental de fungos venenosos pode causar falência renal/hepática severa ou óbito em questão de horas. Reduzir a margem de erro na identificação de espécimes é uma questão direta de preservação da vida.

3. Justificativa

- **Relevância social, econômica ou acadêmica:** Socialmente, previne envenenamentos acidentais. Academicamente e tecnologicamente, o projeto demonstra o poder de modelos transparentes de Machine Learning (*Explainable AI*) na tomada de decisão em cenários de risco crítico, onde falsos negativos (classificar um venenoso como comestível) devem ser zerados.
- **Trabalhos semelhantes (breve revisão):** Aplicações comerciais como o *PictureMushroom* ou *PlantNet*, que utilizam Visão Computacional profunda. O diferencial da nossa proposta é um sistema focado na **morfologia estrutural e olfativa explicável**, permitindo que o usuário entenda *o porquê* da decisão do modelo através das regras do algoritmo, sem depender exclusivamente da qualidade da foto.

4. Objetivos

- **Objetivo geral:** Desenvolver uma aplicação preditiva baseada em Machine Learning capaz de classificar a toxicidade de cogumelos com 100% de confiabilidade e risco zero de falsos negativos.
- **Objetivos específicos:**
 1. Implementar o pré-processamento e codificação dos dados categóricos mapeados na fase de EDA.
 2. Treinar, validar e otimizar um modelo de **Árvore de Decisão** (DecisionTreeClassifier).
 3. Exportar o modelo treinado e criar uma interface interativa (web/API) para simulação de inspeções em tempo real.
 4. Extrair e exibir a árvore de decisão visualmente para garantir transparência na recomendação dada ao usuário.

5. Solução Proposta

- **Como a IA será utilizada:** A Inteligência Artificial atuará como um motor de inferência probabilístico e lógico. Ao receber os atributos morfológicos inseridos pelo usuário (odor, cor das brânquias, esporos, habitat e chapéu), o modelo percorre a estrutura de nós treinada e entrega a classificação binária imediata (*Comestível* ou *Veneno*), acompanhada da margem de certeza.
- **Fluxo geral da solução:**

Entrada do usuário (Formulário/Menu) → Pipeline Encoding → Modelo (Árvore de decisão) → Diagnóstico + Explicabilidade (Regra de Decisão)

6. Métodos e Estratégias

- **Escolha da abordagem:** **Árvores de Decisão** (DecisionTreeClassifier).
- **Justificativa:**
 1. **Explicabilidade Total (Caixa-Branca):** Em aplicações de saúde e sobrevivência, o usuário precisa entender a regra gerada pela IA ("*Veneno* devido à combinação: *Sem odor + Brânquia Branca + Esporo Verde*").
 2. **Adequação aos Dados:** O algoritmo lida nativamente com atributos categóricos nominais e relações não-lineares/condicionais complexas mapeadas anteriormente.
 3. **Controle de Risco:** Permite ajustar hiperparâmetros (como max_depth e pesos de classe) para priorizar a eliminação absoluta de falsos positivos de segurança.

7. Base de Dados ou Ambiente de Busca

- **Origem dos dados:** *UCI Machine Learning Repository* (Base clássica publicada originalmente pelo livro *The Audubon Society Field Guide to North American Mushrooms*).
- **Quantidade de registros:** 8.124 espécimes reais mapeados.
- **Variáveis selecionadas:**
 - **Preditoras:** odor, cor_branquias, cor_esporos, regioao, cor_chapeu.
 - **Alvo (Target):** tipo (*Comestível* vs *Venenoso*).
- **Como serão tratados os dados:**
 - Mapeamento e tradução das categorias.
 - Manutenção intencional da frequência amostral (sem remoção de duplicatas biológicas).
 - Codificação das variáveis categóricas via LabelEncoder / OneHotEncoder.
 - Divisão estratificada em conjuntos de Treino 70% e Teste 30%.